

РОССИЙСКИЙ УНИВЕРСИТЕТ ДРУЖБЫ НАРОДОВ

Факультет искусственного интеллекта

Кафедра искусственного интеллекта

ОТЧЁТ О ЛАБОРАТОРНОЙ РАБОТЕ

по дисциплине «Прикладная статистика и анализ данных»

Лабораторная работа № 2

Тема: Регрессия, мультиколлинеарность, множественные сравнения,
байесовские выводы и ресемплинг

Студентка:	Алмазова Е.А., ЗФИмд-01-25, Фундаментальная информатика и информационные технологии
Преподаватель:	Курашкин С.О., доцент, кандидат технических наук
Дата выполнения:	«01» декабря 2025 г.
Оценка/подпись:	_____

Содержание

Введение.....	3
Теоретические основы	4
Описание данных и инструментов	6
1 Информация о датасете Hotel bookings	6
2 Правила предварительной очистки	8
3 ПО и версии библиотек	8
Методика и план эксперимента	9
1 Схема семплирования и предобработка	9
2 Методы анализа.....	10
Результаты и их анализ.....	11
1 Описательные статистики	11
2 OLS-модель и FDR-контроль.....	11
3 Диагностика мультиколлинеарности.....	13
4 Сравнение с Ridge/Lasso.....	13
5 Байесовская модель и PPC	13
6 Оценка устойчивости.....	15
Выводы	16
Список использованной литературы	17

Введение

Ранее при изучении моделей, используемых в области анализа данных и машинного обучения, мы отмечали важность проведения качественного разведочного анализа и построения надежных конвейеров обработки. Теперь мы переходим к не менее важному шагу в процессе обучения моделей, а именно, к их интерпретации, контролю ошибок при множественных сравнениях и оценке неопределенности параметров. Лабораторная работа целиком охватывает вторую часть курса «Прикладная статистика и анализ данных».

Целью лабораторной работы является освоение комплексного набора навыков по построению, сравнению и валидации моделей. Для достижения цели решены следующие задачи:

- построение и сравнение нескольких спецификаций множественной линейной регрессии;
- диагностика мультиколлинеарности и применение регуляризации;
- корректная проверка семейства гипотез с контролем FDR;
- проведение байесовской регрессии с априорами и постериорной проверкой предсказаний;
- оценка доверия к выводам с помощью бутстрепа и перестановочных тестов.

Для выполнения задач лабораторной работы используется открытый набор данных Olist Brazilian E-commerce. Это анонимизированные реальные коммерческие данные о 100000 заказах в период с 2016 по 2018 г., сделанных в различных магазинах Olist в Бразилии. Наиболее удобный представляется использование оригинального датасета, выложенного на сайте [kaggle.com](https://www.kaggle.com) [2]. Всего датасет включает в себя 9 взаимосвязанных таблиц, 8 из которых мы будем использовать в работе.

По завершении работы ожидается сформированное умение:

- задавать и интерпретировать линейные модели с взаимодействиями;
- диагностировать и снижать мультиколлинеарность;
- применять FDR-контроль к семействам проверок;
- формулировать априоры и читать апостериор, выполнять PPC;
- строить бутстреп-ДИ и перестановочные р-значения;
- оформлять воспроизводимый отчёт.

Теоретические основы

В работе используются основные методы и понятия из областей прикладной статистики и построения регрессионных моделей. В частности, строится множественная линейная регрессия (OLS) [6], базовая спецификация которой записывается формулой 1:

$$y = X\beta + \varepsilon, \varepsilon \sim N(0, \sigma^2 I). \quad (1)$$

Оценки коэффициентов находятся методом наименьших квадратов (МНК):

$$\hat{\beta} = (X^T X)^{-1} X^T y. \quad (2)$$

Для сравнения вложенных моделей можно воспользоваться частичными F-тестами или девиансами. Для сравнения спецификаций используется дисперсионный анализ в смысле разложения суммы квадратов и тестирования добавочных блоков признаков. При тестировании множества коэффициентов/контрастов применяется контроль FDR, который заключается в упорядочивании р-значений и нахождении максимального индекса k , при котором $p_k \leq \frac{k}{m} \alpha$. Реализация данного теста была выполнена в библиотека statsmodels [5].

Диагностика мультиколлинеарности производится с помощью оценки значения инфляции дисперсии (VIF), которое вычисляется по формуле 3:

$$VIF_j = \frac{1}{1-R_j^2}, \quad (3)$$

где R_j^2 – это коэффициент детерминации регрессии x_j на все прочие признаки. Большие значения VIF, обычно больше 10, указывают на нестабильность оценок и раздутые стандартные ошибки. Тогда можно использовать регуляризованные оценки Ridge (формула 4) и Lasso (формула 5) [4], причем Lasso также дает разреженность и встроенный отбор признаков, но чувствителен к масштабированию.

$$\hat{\beta}_\lambda = \operatorname{argmin}_\beta |y - X\beta|_2^2 + \lambda|\beta|_2^2. \quad (4)$$

$$\hat{\beta}_\lambda = \operatorname{argmin}_\beta |y - X\beta|_2^2 + \lambda|\beta|_1. \quad (5)$$

В рамках построения байесовской линейной регрессии [3] задается модель правдоподобия:

$$y|X, \beta, \sigma^2 \sim N(X\beta, \sigma^2 I) \quad (6)$$

и априорные распределения параметров. Тогда постериорное распределение оценивается с помощью MCMC (NUTS) и постериорно-предсказательная проверка (PPC) сравнивает предсказания модели с реальными данными.

При нарушениях гауссовости/гомоскедастичности либо сложной зависимой структуре данных особенно полезны операции ресемплинга для оценки доверительных интервалов (ДИ) статистических функционалов [1]. Так, мы будем применять бутстреп. Для параметра $\theta = g(X, y)$ формируются В бутстреп-выборки с возвращением, откуда получается оценка 7:

$$\hat{\theta}^b b = 1^B. \quad (7)$$

ДИ задается по процентилям: $[q\alpha/2, q_{1-\alpha/2}]$. Также мы произведем перестановочные тесты. Для статистики T переставляются метки по нулевой гипотезе, и тогда p -значение вычисляется по формуле 8:

$$p = \frac{1 + \sum_{b=1}^B \mathbb{I}(|T^b| \geq |T_{obs}|)}{1+B}. \quad (8)$$

Описание данных и инструментов

1 Информация о датасете Hotel bookings

Для выполнения задач лабораторной работы используется открытый набор данных Olist Brazilian E-commerce. Это анонимизированные реальные коммерческие данные о 100000 заказах в период с 2016 по 2018 г., сделанных в различных магазинах Olist в Бразилии. Наиболее удобный представляется использование оригинального датасета, выложенного на сайте [kaggle.com](https://www.kaggle.com) [2]. Из исходного набора 9 взаимосвязанных таблиц были выбраны 8 (orders, order_items, order_payments, products, sellers, customers, geolocation, product_category_name_translation) и выполнена агрегация на уровне товарных позиций, объединены данные о ценах, способах доставки и категориях товаров (рис. 1) [2].




Рисунок 1. Структура датасета

Для анализа была сформирована случайная подвыборка объёмом 50 тыс. наблюдений. Целевой переменной является цена товара (price). В качестве предикторов рассматриваются четыре прокси «глубины категории», извлечённые из текстового поля product_category_name:

- category_depth – количество подчёркиваний в названии категории + 1;
- category_tokens – число токенов после замены подчёркиваний на пробелы;
- category_length – длина строки названия категории;
- is_complex_category – бинарный признак (глубина ≥ 3).

Кроме того, в модель включены числовые и временные признаки: freight_value (стоимость доставки), payment_installments (число платежей), purchase_hour (час покупки), purchase_dayofweek (день недели), is_weekend (индикатор выходного), при этом предпоследнему присуща порядковая шкала.

2 Правила предварительной очистки

В рамках предварительной очистки датасета для дальнейшей работы над ним были проведены следующие процедуры:

1. Агрегация таблиц.
2. Вычисление производных признаков, в частности, общий объём оборота товаров (GMV), количество видов товаров в заказе.
3. Преобразование временных категорий в специальный формат и вычисление производных признаков, в частности, время доставки и задержка доставки.
4. Выделение случайной подвыборки из 50000 строк.
5. Вычисление прокси «глубины категории» и некоторых других временных признаков.
6. Выбор колонок только в числовом формате.
7. Удаление строк с пропусками.

3 ПО и версии библиотек

Программный код был написан на языке программирования Python (версия 3.11.13) в среде разработки Kaggle. В работе были также использованы следующие библиотеки и их версии:

- pandas: 2.2.3;
- numpy: 1.26.4;
- scikit-learn: 1.2.2;
- seaborn: 0.12.2;
- matplotlib: 3.7.2;
- statsmodels: 0.14.5;
- scipy: 1.15.3;
- pymc: 5.25.1;

– arviz: 0.21.0.

Значение SEED для генерации псевдослучайных чисел выбрано равным 42.

Методика и план эксперимента

1 Схема семплирования и предобработка

Из полного датасета Olist взята случайная выборка 50 тыс. строк. Такой размер обеспечивает баланс между репрезентативностью и вычислительной сложностью, особенно для байесовских методов. Какого-либо специального метода для выбора случайных строк не требуется, поскольку в датасете не имеется значимых временных рядов. После очистки от пропусков итоговый объём составил 49 999 наблюдений.

Предобработка выполнена в пайплайне через ColumnTransformer для предотвращения утечек. К числовым признакам пайплайном предусмотрено применения импутации пропусков по стратегии медианы, к категориальным – по стратегии наиболее частого значения, хотя это уже не требуется. Также числовые признаки были масштабированы с применением StandardScaler, категориальные признаки преобразованы с использованием One-Hot кодирования.

Целевой переменной определена цена товара (price), а в качестве ключевых предикторов рассмотрены четыре прокси глубины категории, извлечённые из текстового поля product_category_name:

- category_depth – количество подчёркиваний + 1;
- category_tokens – число токенов после замены подчёркиваний;
- category_length – длина строки;
- is_complex_category – бинарный признак (глубина ≥ 3).

Данные были разделены на обучающую (34 999 наблюдений, 70%) и тестовую (15 000 наблюдений, 30%) выборки.

2 Методы анализа

Нами построена базовая OLS-модель для оценки влияния глубины категории на цену, которая использует метод наименьших квадратов и является эталоном для сравнения остальных моделей, позволяя получить интерпретируемые коэффициенты и p -значения. Для борьбы с мультиколлинеарностью и стабилизации оценок применены Ridge (L2-регуляризация) и Lasso (L1-регуляризация) регрессии с подбором гиперпараметра λ по 5-кратной кросс-валидации. Байесовская линейная регрессия была основана на следующих умеренно информативных априорных распределениях: коэффициенты имеют нормальное распределение $N(0,5)$, свободный член – $N(0,10)$, дисперсия ошибок – $HalfCauchy(10)$. В качестве гиперпараметров выступили метод сэмплирования NUTS, 2 цепи, 1000 итераций настройки и 1000 итераций сбора. Диагностика сходимости осуществлялась через R-hat.

Нами был применен непараметрический бутстреп по объектам, то есть случайная выборка с возвращением из исходной выборки. Количество итераций = 500. Главной статистикой для оценки выбран R^2 , как наиболее удобно интерпретируемая метрика. ДИ строились по процентильному методу, где 95% доверительный интервал – это отрезок [2,5 перцентиль; 97,5 перцентиль].

Для перестановочного теста были сформулированы нулевая гипотеза H_0 : модели имеют одинаковое качество, то есть разность метрик = 0; и альтернативная гипотеза H_1 : модели отличаются по качеству. В качестве тестовой статистики использовалась разность RMSE. Применяется перестановка меток предсказаний:

1. Предсказания обеих моделей объединяются в один массив;
2. Массив случайно перемешивается;

3. Перемешанные предсказания разделяются обратно на две группы;
4. Вычисляется разность метрик на перемешанных данных.

Количество перестановок = 500. Критерием принятия решения является двусторонний тест при уровне значимости = 0,05 – если р-значение меньше 0,05, нулевая гипотеза отвергается.

Результаты и их анализ

1 Описательные статистики

Средняя цена товара составила 120,5, стандартное отклонение = 185,83, с диапазоном от 0,85 до 6729. Похоже, что распределение цены имеет тяжелый правый хвост, что характерно для товаров.


2 OLS-модель и FDR-контроль

Обученная OLS-модель показывает качество $R^2 = 0,2179$. Встроенные параметры модели показывают, что только `category_length` является незначимым коэффициентом. `category_depth` и `category_tokens` увеличивают цену, причем каждая единица ассоциирована с поднятием цены примерно на 8.68, тогда как `is_complex_category` уменьшает цену. FDR-контроль подтверждает эти данные (табл. 1).

Таблица 1. Диагностика прокси признаков «глубины категории»

Признак	Коэффициент	FDR p-значение
<code>category_depth</code>	8.6824	0
<code>category_tokens</code>	8.6824	0
<code>category_length</code>	-0.2921	0.2552
<code>is_complex_category</code>	-41.1083	0

Заметим, что после коррекции FDR коэффициенты практически не поменялись, что показывает рисунок 2.



Это может быть связано с тем, что наиболее сложные категории являются специализированными товарами с меньшей средней стоимостью, что подтверждают графики (рис. 3).




Рисунок 3. Гистограмма глубины категории и ее взаимосвязь с ценой

3 Диагностика мультиколлинеарности

Анализ VIF выявил сильную мультиколлинеарность между признаками category_depth и category_tokens ($VIF > 10$), что объясняется их зависимостью по способу задания – их способы расчета одинаковы.

4 Сравнение с Ridge/Lasso

Все три модели демонстрируют практически идентичное качество по метрикам RMSE, MAE, R^2 (рис. 4).

Model	RMSE	MAE	R^2
OLS	159.9091	77.1109	0.2178
Ridge	159.9092	77.0747	0.2178
Lasso	159.9239	77.0713	0.2177

Рисунок 4. Сравнение моделей

Качество построенных моделей невысоко, они объясняют лишь 22% дисперсии, что свидетельствует о недостаточности выбранных признаков для работы с данными или необходимости отказаться от линейных моделей. Регуляризация не улучшила предсказательную способность линейной регрессии, что связано с отсутствием явного переобучения OLS-модели.

5 Байесовская модель и PPC

Байесовская модель была успешно обучена, обе цепи сошлись ($R\text{-hat} = 1.002 < 1.01$). Мы также получили постериорные распределения (рис. 5).




Рисунок 5. Визуализация постериорных распределений

PPC (рис. 6) показывает хорошую калибровку модели, а именно, 97% реальных наблюдений попадают в 95% прогнозный интервал. R^2 на тестовой выборке составляет 0,2164, что близко к результатам предыдущих моделей.




Рисунок 6. Визуализация результатов PPC

6 Оценка устойчивости

Нами был найден бутстреп-ДИ для R^2 OLS-пайплайна: [0,1937; 0,2433] (рис. 7).




Рисунок 7. Бутстреп распределение R^2 OLS-пайплайна

Перестановочный тест не выявил значимой разницы между OLS и Ridge моделями: разница RMSE составила -0.0001, что меньше р-значения, равного 1.

Выводы

В рамках выполнения данной лабораторной работы мы получили комплексный набор навыков по построению, сравнению и валидации моделей на основе открытого набора данных Olist Brazilian E-commerce, который представляет собой анонимизированные реальные коммерческие данные о 100000 заказах в период с 2016 по 2018 г., сделанных в различных магазинах Olist в Бразилии. Для достижения цели мы построили и сравнили нескольких спецификаций множественной линейной регрессии; диагностировали мультиколлинеарности и применили регуляризацию; проверили семейство гипотез с контролем FDR; провели байесовскую регрессию с априорами и постериорной проверкой предсказаний; оценили доверие к выводам с помощью бутстрепа и перестановочных тестов.

В результате проведенной работы можно сделать следующие выводы. Глубина категории оказывает статистически значимое влияние на цену товара, увеличивая ее с каждой единицей на 8,68. Сложные категории связаны со снижением цены ввиду узкой специализированности и низкой средней стоимостью таких товаров. Качество построенных моделей невысоко, они объясняют лишь 22% дисперсии, что свидетельствует о недостаточности выбранных признаков для работы с данными или необходимости отказаться от линейных моделей. Регуляризация не улучшила предсказательную способность линейной регрессии, что связано с отсутствием явного переобучения OLS-модели. Байесовский подход дал сходные результаты с частотными методами, но позволил работать с неопределенностью через апостериорные распределения. Также FDR-контроль показал важность при тестировании семейств гипотез, а бутстреп и перестановочные тесты оказались незаменимыми при проверке устойчивости результатов.

Однако наше исследование имеет некоторые ограничения. Во-первых, наши модели обучались на ограниченном наборе данных: лишь 50000 объектов. Во-вторых, для сокращения работы программы и упрощения построения байесовской модели многие категориальные признаки не были учтены во время обучения и предсказания. В-третьих, мультиколлинеарные прокси использовались в данных одновременно, что могло ухудшить качество моделей.

В дальнейшем рекомендуется:

- расширить процесс предобработки данных и применить импутацию;
- использовать другие категориальные признаки и способы кодирования;
- применить нелинейные модели.

Список использованной литературы

[1] Бутстрэп анализ : Tidy Data блог. – 2025. – URL: <https://tidydata.ru/bootstrap> (дата обращения: 01.12.2025).

[2] Датасет Brazilian E-Commerce : сайт [kaggle.com](https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce). – 2021. – URL: <https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce> (дата обращения: 01.12.2025).

[3] Carlin, B. P. Bayes and Empirical Bayes Methods for Data Analysis / B. P. Carlin, T. A. Louis. – 2nd ed. – New York : Chapman and Hall/CRC, 2000. – 416 p.

[4] Linear Models : документация библиотеки [scikit-learn](https://scikit-learn.org/stable/modules/linear_model.html). – 2025. – URL: https://scikit-learn.org/stable/modules/linear_model.html (дата обращения: 01.12.2025).

[5] Multiplerests : документация библиотеки [stats-models](https://www.statsmodels.org/dev/generated/statsmodels.stats.multitest.multipletests.html). – 2025. – URL: <https://www.statsmodels.org/dev/generated/statsmodels.stats.multitest.multipletests.html> (дата обращения: 01.12.2025).

[6] Ordinary Least Squares (OLS) : Vandita Gupta : geeksforgeeks.org. – 2025.
– URL: <https://www.geeksforgeeks.org/machine-learning/ordinary-least-squares-ols/>
(дата обращения: 01.12.2025).